


Proyecto: El Comediante de la IA: Tuneando Parámetros para el Humor

Objetivos del Proyecto

El objetivo principal es que los estudiantes utilicen las APIs de modelos de frontera (como OpenAI GPT y Google Gemini) y exploren cómo los parámetros de llamada, en particular la temperatura y el límite de tokens, afectan la creatividad y la calidad de los chistes generados.

Configuración Inicial

- Entorno de Trabajo: Se debe trabajar en python con visual code.
- Configuración de Claves: Se Debe configurar las claves API para OpenAI y Google (Gemini) en un fichero oculto llamado .env.
 - Las claves se cargan mediante librerías como dotenv.
 - Se establecerá la conexión con la API de OpenAI (clase OpenAI) y la de Google (usando google.generativeai.configure() o el cliente de OpenAI como alternativa).



3. Fase 1: Establecer la Base (Prompt Engineering)

Los LLM requieren un prompt de sistema (que da el contexto general o el rol) y un prompt de usuario (el mensaje real).

- Prompt de Sistema (Contexto): Se sugiere usar un rol que fomente el humor, como: "Eres un asistente que es genial contando chistes".
- Prompt de Usuario (La Pregunta): Se sugiere usar la petición estándar: "Cuenta un chiste divertido para una audiencia de científicos de datos".

Estos prompts deben organizarse en una lista de diccionarios, especificando el role (system o user) y el content.

4. Fase 2: Experimentación con Parámetros

Se debe realizar llamadas a la API utilizando al menos un modelo de GPT (ej: gpt-4o-mini, gpt-4.1-mini, o gpt-4.1) y un modelo de Gemini (ej: gemini-2.0-flash o gemini-2.5-flash).

A. Ajuste de Temperatura (Creatividad/Originalidad)

La temperatura es un parámetro crucial que pueden ajustar, típicamente entre cero y uno.

Configuración	Valor	Resultado esperado (Según las fuentes)
Baja Aleatoriedad	Cerca de 0.0 (e.g., 0.4)	La salida es menos aleatoria, menos creativa y más repetible.
Alta Creatividad	Cerca de 1.0 (e.g., 0.7)	La salida es lo más creativa y aleatoria posible.

Tarea:

1. Generar un chiste con Temperatura = 0.2 (Muy enfocado).
2. Generar un chiste con Temperatura = 0.6 (Nivel medio de creatividad).
3. Generar un chiste con Temperatura = 0.9 (Máxima aleatoriedad).
4. Analizar si el chiste con alta temperatura es más gracioso o simplemente más incoherente.

B. Ajuste de la Longitud de Salida (max_tokens)

Se debe utilizar el parámetro max_tokens para limitar la extensión del chiste, asegurando que no divague demasiado. Este parámetro se usa, por ejemplo, en las llamadas a Claude (Anthropic), con un valor como max_tokens=200, y puede aplicarse a los demás modelos.

Tarea:

1. Generar un chiste sin límite de tokens (o un límite alto).
2. Generar el mismo chiste limitando la salida a 50 tokens.
3. Evaluar si la restricción de tokens obliga al modelo a ser más conciso, mejorando el impacto del remate.

5. Fase 3: Comparación de Modelos y Análisis

Se pide a los estudiantes comparar los chistes generados por:

- Diferentes versiones del mismo proveedor (ej: GPT 3.5 Turbo vs. GPT 4.1 Mini).
- Modelos de diferentes proveedores (GPT vs. Gemini).

Deben registrar qué combinación de modelo y parámetros (temperature, max_tokens) produjo el chiste "más divertido".

6. Fase 4 (Limitaciones de APIS de pago): Modelos de Código Abierto y Alternativos

Para extender el proyecto, los estudiantes pueden incluir modelos que no sean de frontera o *open source*:

1. Ollama: Utilizar una instalación de Ollama (mencionado en el contexto de la Semana 1) para reemplazar a Anthropic o Google. Pueden cargar modelos como Llama (según la solicitud) o cualquier otro modelo compatible.
2. DeepSeek: Opcionalmente, pueden intentar configurar la clave de DeepSeek y utilizar su modelo deepseek-chat o deepseek-reasoner. DeepSeek se puede acceder a través de la librería cliente de OpenAI, lo cual facilita la implementación.
3. Modelos Chinos (Kimi 2 o Qwen): Aunque las fuentes no mencionan directamente Kimi 2 o Qwen, sí mencionan que la aproximación de usar la librería cliente de OpenAI para conectar con *otros modelos* (como DeepSeek) se ha vuelto popular y es soportada por todos los modelos. Esto sugiere que podrían intentar conectar estos modelos de código abierto o alternativos si estos han adoptado la misma convención de *endpoints*.

Entrega del Proyecto

Los estudiantes deben entregar un cuaderno de Jupyter Lab (o informe) que contenga:

1. El código para conectar y llamar a las APIs de GPT y Gemini.
2. Una tabla comparativa mostrando al menos 6 chistes generados con diferentes combinaciones de modelo, temperatura y max_tokens.
3. Una conclusión sobre qué parámetros y modelos parecieron mejorar la capacidad de contar chistes y cuál fue la combinación más exitosa.

Analogía para el Parámetro de Temperatura:

Imagínese que la IA es un chef preparando una receta de chistes.

- Una Temperatura baja (cerca de 0) es como seguir la receta al pie de la letra, usando ingredientes precisos y obteniendo siempre el mismo resultado predecible (repetible).
- Una Temperatura alta (cerca de 1) es como dejar al chef experimentar y volverse creativo, añadiendo ingredientes aleatorios, especias inesperadas, o inventando la receta sobre la marcha (creativa y aleatoria). El resultado puede ser un plato genial o algo incomible, al igual que los chistes pueden ser muy originales o sin sentido.