



Ingeniería de LLMs: Tu Primera Misión con IA Generativa

Dominando el ecosistema Hugging Face y Google Colab



El Ecosistema Hugging Face y Código Abierto

Bienvenido al mundo del Open Source.



Modelos (>1M)

El cerebro de la IA. Modelos como Llama 3, Mistral o FLUX listos para descargar.



Datasets (>200K)

Colecciones masivas de datos para afinar (Fine-Tuning) y entrenar a tus propios modelos.



Spaces

Aplicaciones interactivas de la comunidad. Ejemplo: Comic Factory, Outsmart o Kolors.

Tu Misión: Construir un Generador de Arte

Desplegaremos el modelo gigante FLUX.1-schnell en la nube para generar imágenes a partir de texto.



Registro de Misión



Cuenta de Google activa.



Cuenta en Hugging Face (huggingface.co).



Aceptar los términos del modelo FLUX.1-schnell.



Configurar tu entorno seguro en Colab.



Vencer el reto de la memoria RAM.

Preparando la "Súper Computadora"

Entorno de
ejecución



Cambiar tipo de
entorno



T4 GPU



Nota del Mentor: Google Colab nos presta un ordenador, pero por defecto usa una CPU normal.

Para que la IA funcione rápido y no dé errores de memoria, es obligatorio activar la Tarjeta Gráfica (GPU).

Tu Llave Maestra (Tokens y Secretos)

Hugging Face



Este token es tu llave para acceder a los modelos.

Google Colab



Guarda tus secretos de forma segura aquí, no en tu código.



Crea un nuevo secreto llamado **HF_TOKEN**, pega tu llave **hf_...** y activa el interruptor "**Acceso** al cuaderno".

Pro-Tip



¡Nunca escribas contraseñas en el código visible! Usa esta "caja fuerte".

Paso 1: Instalación y Autenticación

Comando de consola: El símbolo ! le dice a Colab que no ejecute Python, sino que descargue e instale librerías en la máquina virtual.


```
#1. Instalar librerías e iniciar sesión
!pip install diffusers accelerate torch huggingface_hub

from google.colab import userdata
from huggingface_hub import login

login(userdata.get('HF_TOKEN'))
```

Seguridad: Lee nuestra llave secreta de la "caja fuerte" sin mostrarla en el código.

El Reto de la Memoria



¿El Problema?

El modelo es demasiado grande para la memoria RAM gratuita.
Necesitamos "magia de optimización" para que la máquina no se cuelgue.

Paso 2: Cargar y Optimizar (La Solución)

****Compresión:** Usa números decimales más pequeños para que el cerebro gigante quepa en la memoria.

```
pipe = FluxPipeline.from_pretrained("black-forest-labs/FLUX.1-  
schnell", torch_dtype=torch.bfloat16)  
pipe.enable_sequential_cpu_offload()  
pipe.vae.enable_slicing()  
pipe.vae.enable_tiling()
```

****El Malabarista:** Mueve partes del modelo entre la CPU y la GPU milisegundo a milisegundo, cargando solo lo necesario.

Corta la imagen en 'azulejos' procesables.

Paso 3: Generación de la Obra Maestra

Asegura resultados idénticos. Con el mismo texto, la IA generará exactamente la misma imagen.

```
generator = torch.Generator(device="cpu").manual_seed(0)
prompt = "A futuristic class full of students learning
AI coding..."

image = pipe(prompt, guidance_scale=0.0,
             num_inference_steps=4,
             max_sequence_length=256,
             generator=generator).images[0]

image.save("mi_obra_maestra.png")
```

Schnell es una versión rápida. Solo necesita 4 "pasadas" para refinar el ruido hasta el dibujo final.

Admira tu Obra de Arte

1. Ve al menú lateral izquierdo y haz clic en la carpeta 📁.
2. Pulsa el botón de **Actualizar** (flecha circular).
3. Haz doble clic en **mi_obra_maestra.png** para verla, o usa los tres puntos para descargarla.



Misión Extra: El poder del Prompt

Vuelve al código y cambia la instrucción al inglés. ¿Un gato astronauta?
¿Una ciudad cyberpunk? Modifica, ejecuta y genera nuevas ideas.

El Gran Bazar de Pipelines

Los Pipelines son la API de alto nivel de Hugging Face. Nos permiten realizar inferencia de inteligencia artificial con apenas un par de líneas de código.

```
!pip install transformers datasets soundfile sentencepiece sacremoses
```



El truco de la velocidad: Al usar Pipelines, añade siempre **device="cuda"**. Esto le dice a Python que use la tarjeta gráfica en lugar del procesador normal, ¡haciendo que vaya 100 veces más rápido!

Superpoder 1: Análisis y Reconocimiento (Texto)

😞 Análisis de Sentimiento

- Tarea: "sentiment-analysis"
- Evalúa si el tono emocional es positivo o negativo.

El truco de la velocidad

```
clasificador = pipeline("sentiment-analysis", device="cuda")  
  
res = clasificador("¡Estoy súper emocionado de aprender!")
```

🔍 Reconocimiento (NER)

- Tarea: "ner" (Nombres, organizaciones, ubicaciones).

🏆 Mentor Note

Las IAs leen partiendo palabras en 'tokens'. Esta instrucción vuelve a pegar los trozos que pertenecen a la misma entidad (Ej: une "EE", ":", "UU" en "EE.UU:").

```
...  
aggregation_strategy="simple"
```


Superpoder 2: Respuestas y Traducción (Conocimiento)

Preguntas y Respuestas (QA)

- Actúa como un buscador inteligente leyendo comprensión.
- Extrae la respuesta exacta de un context basándose en una question.

```
qa = pipeline("question-answering", device="cuda")
```

El truco de la velocidad



Traducción Automática

- Tarea: "translation_en_to_fr" usando el modelo Helsinki-NLP/opus-mt-en-fr.
- Convierte texto de un idioma a otro de forma automática.

Superpoder 3: Darle Voz a la IA (Audio)

```
import soundfile as sf

tts = pipeline("text-to-speech", model="facebook/mms-tts-spa",
               device="cuda")

audio = tts("Hola, soy un experto en inteligencia artificial.")

sf.write("saludo.wav", audio["audio"],
         samplerate=audio["sampling_rate"])
```



Mentor Note

La IA no devuelve un archivo mp3 mágico, sino una matriz matemática (onda). Usamos la librería **soundfile** (**sf.write**) para empaquetar esa onda y su tasa de muestreo (**sampling_rate**) en un archivo .wav descargable.

Misión Cumplida

Has dominado con éxito tu primera inmersión en la Ingeniería de LLMs.

-  Entornos de GPU en la nube (Colab T4). 
-  Gestión segura de Tokens API. 
-  Optimización de memoria (Offload/Slicing). 
-  Generación de imágenes locales con FLUX.1. 
-  Implementación de Pipelines de NLP y Audio. 

El universo Open Source es tuyo. ¿Qué vas a construir ahora?