


Explorando las APIs de Bajo Nivel: El Motor de los LLMs

Disecccionando tokenizadores y el idioma nativo de la inteligencia artificial.



MÁQUINA



[1254]

[88]

[452]

[912]

[111]

[673]

[34]



El Gran Problema


Hola,
¿cómo estás?

**Los LLMs no
entienden palabras.
Solo entienden
matemáticas.** ⚠

**Los LLMs no
entienden palabras.
Solo entienden
matemáticas.** ⚙

01001000
01101111

1111011
00
105
101
011
010



La Solución: El Tokenizador



El *tokenizador* es el traductor universal. Convierte nuestro texto en una secuencia matemática (IDs) que el modelo puede procesar.

Paso 1: Preparando el Laboratorio



Entorno: Google Colab listo para la ejecución.



Librerías Clave: `datasets`, `transformers`, `huggingface_hub` instaladas correctamente.



Autenticación: `HF_TOKEN` cargado desde **Secrets** y sesión iniciada.

Requisito previo: Haber aceptado los términos de Llama 3.1 en la plataforma de Hugging Face con permisos de escritura.

Paso 2: Instanciando el Motor

Concepto



Atención: No son intercambiables.
Cada modelo requiere su propio
diccionario matemático.

Código

```
modelo_id = 'meta-llama/Meta-  
Llama-3.1-8B'  
  
tokenizer = AutoTokenizer.  
from_pretrained(modelo_id,  
trust_remote_code=True)
```


ENCODE: De Humano a Máquina

Paso 3: Codificación

Estoy entusiasmado por mostrarles a mis ingenieros de LLM los Tokenizadores en acción.



```
tokens = tokenizer.encode(texto)
```



[128000, 34952, 220, 5432, 891, 220, 22187, 220, 80878, ...]

Representación numérica lista para el modelo.


Autopsia de una Frase

El modelo no ve palabras enteras, sino **fragmentos** (sub-palabras) optimizados estadísticamente.




La Regla de Oro de las Longitudes

Dependiendo del idioma, la longitud no es 1:1. Como regla general, un token equivale a aproximadamente ~4 letras.



85 Caracteres



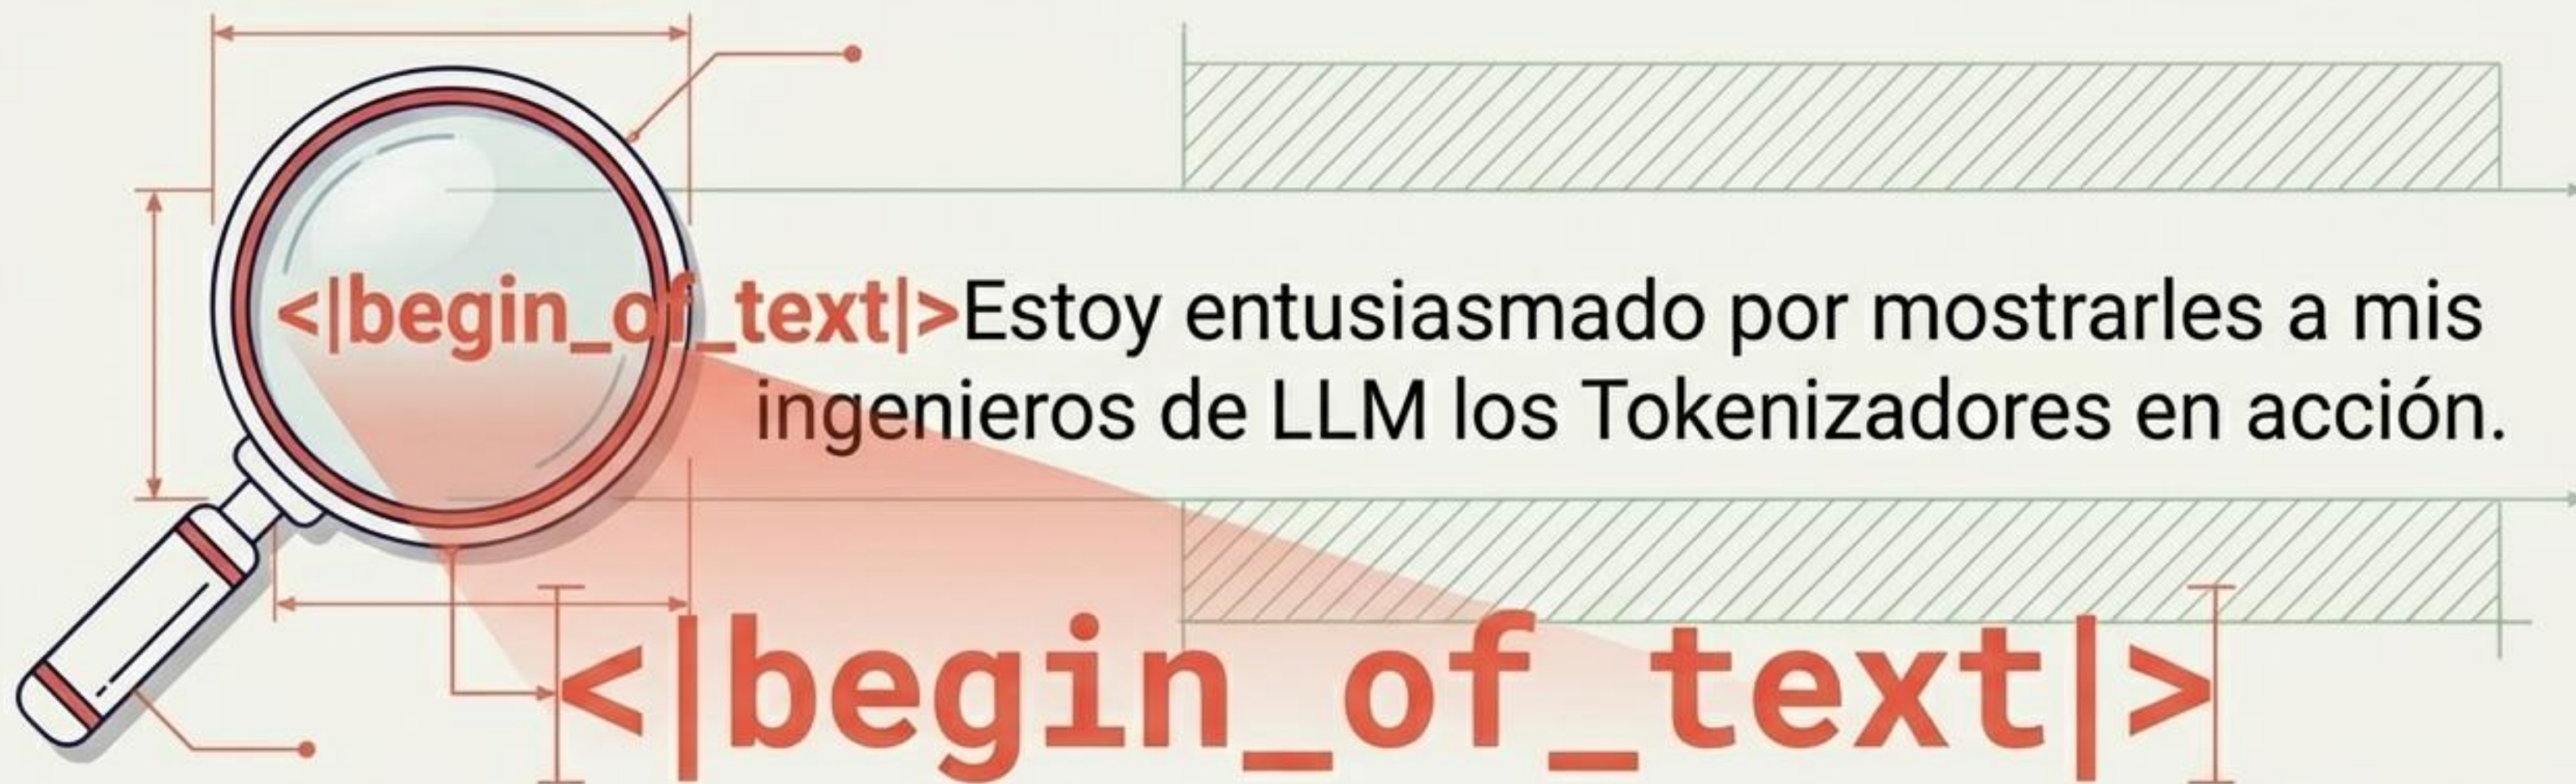
22 Tokens

DECODE: Ingeniería Inversa

Paso 4: Descodificación



Revelando lo Invisible



Los tokenizadores inyectan **Tokens Especiales** que nosotros no escribimos.

- Sirven como **señales de tráfico estructurales** para que el modelo sepa dónde empieza y termina la información.

Troceando la Realidad

Función: **batch_decode**



Esta función nos permite **ver la realidad exacta del modelo**: cómo lee el texto lote a lote, token por token.

Plantillas de Chat (Paso 5)

Los modelos Instruct necesitan estructura.



Aplicando la Plantilla

```
mensajes = [  
  {'role': 'system', 'content': 'Eres...'}  
  {'role': 'user', 'content': 'Explicame...'}  
]
```

apply_chat_template

```
<|start_header_id|>system<|end_header_id|>  
Eres...  
<|start_header_id|>user<|end_header_id|>  
Explicame...
```


El Reto Final: Llama vs. Qwen

	Meta-Llama-3.1-8B 	Qwen2.5-Coder-7B 
Focus Enfoque	Optimizado para lenguaje natural humano.	Optimizado para programación.
Behavior Comportamiento	Agrupar letras en sílabas y palabras comunes.	Tokeniza la sintaxis de código, la indentación y los espacios en blanco de forma distinta para mantener la estructura lógica.



```
PHI4 = "microsoft/Phi-4-mini-instruct"  
DEEPSEEK = "deepseek-ai/DeepSeek-V3.1"  
QWEN_CODER = "Qwen/Qwen2.5-Coder-7B-  
Instruct"
```


Resumen del Laboratorio



1. El Traductor Universal

Los tokenizadores son el paso obligatorio que convierte nuestro lenguaje en las matemáticas (IDs) el LLM entiende. No hay IA sin tokenizador.



2. El Mundo de las Sub-palabras

Los modelos no leen palabras completas, leen fragmentos estadísticos (~4 letras por token en promedio).



3. Control Invisible

Los Tokens Especiales y las Plantillas de Chat son la estructura oculta matemática que guía el comportamiento del modelo.

Texto de entrada (Prompt):

Estoy entusiasmado por mostrarles a mis ingenieros de LLM los tokenizadores en acción.

1. Ejecutar `tokenizer.encode()`

2. Ejecutar `tokenizer.decode()`

SALIDA DE CÓDIGO: REPRESENTACIÓN EN ARRAY DE IDS (LO QUE VE EL MODELO)

```
[128000, 34952, 220, 5432, 891, 220, 22187, 220, 80878, 220, 1097, 220, 19119, 220, 332, 90, 220, 4201, 220, 76469, 220, 18344, 220, 1254, 88, 452, 220, 4241, 220, 14213, 1046]
```

VISUALIZACIÓN: MAPEO DE TEXTO A TOKENS (SUB-PALABRAS)

128000	34952	220	5432	891	220	22187	220		
< begin_of_text >	Estoy	[espacio]	entusias	mado	[espacio]	por	[espacio]		
80878	220	1097	220	19119	220	332	90	220	
mostrarles	[espacio]	a	[espacio]	mis	[espacio]	inGen	ieros	[espacio]	
4201	220	76469	220	18344	220	1254	88	452	220
de	[espacio]	LLM	[espacio]	los	[espacio]	token	iz	adores	[espacio]
4241	220	14213	1046						
en	[espacio]	acción	.						